

Métricas de evaluación y tests estadísticos para machine learning

Clasificación binaria

La **clasificación binaria** consiste en que un dato puede ser positivo o negativo. Esto provoca que cuando hagamos una predicción tengamos 4 posibilidades diferentes y de ahí sale la matriz de confusión:

	Real Positivo	Real Negativo
Predicción Positivo	TP	FP
Predicción Negativo	FN	TN

Accuracy

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

Esta medida calcula la proporción total de aciertos. El problema es que en datasets desbalanceados esta métrica puede engañar.

Sensitivity o recall

$$Sen = \frac{TP}{TP + FN}$$

Esta medida calcula de los positivos reales cuántos detecto.

Specificity (TNR)

$$Spe = \frac{TN}{TN + FP}$$

Esta medida calcula de los negativos reales cuántos clasifico bien.

Precision

$$Pre = \frac{TP}{TP + FP}$$

Esta medida calcula, de los que predigo como positivo, cuántos son realmente positivos.

F1-score

$$F1 = \frac{2 \cdot \text{Pre} \cdot \text{Rec}}{\text{Pre} + \text{Rec}}$$

Es la media armónica de la precisión y el recall. Esta medida sirve cuando hay desbalanceo e importa el equilibrio entre detectar y no equivocarse.

Youden's index

$$\text{Youden} = \text{Sensitivity} + \text{Specificity} - 1$$

Esta medida mide el equilibrio entre ambas clases. Va entre 0 y 1:

- 0 significa clasificador aleatorio.
- 1 significa clasificador perfecto.

Cohen's Kappa (K)

$$K = \frac{\text{Acc} - p_e}{1 - p_e}$$

donde p_e es la precisión esperada por azar.

Esta medida mide cuánto mejora la precisión respecto al azar.

- 1 significa perfecto.
- 0 significa azar.
- -1 significa peor que azar.

MCC (Matthew's correlation coefficient)

$$\text{MCC} = \frac{\text{TN} \cdot \text{TP} - \text{FN} \cdot \text{FP}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}}$$


Esta medida calcula la correlación entre la predicción y la realidad. Va de -1 a 1:

- 1: perfecto.
- 0: azar.
- -1: completamente incorrecto.

Esta es la mejor métrica cuando hay desbalanceo.

ROC Curve

Esta métrica es una gráfica.



En el eje Y ponemos el sensitivity y en el eje X el specificity. Cada punto de la curva tiene un umbral diferente. Si la curva está cerca de la esquina superior izquierda la curva es buena.

AOC (Area Under Curve)

Se calcula como el área bajo la curva ROC.

Va de 0 a 1:

- 0.5: Azar.
- 0.8: Bueno.
- 0.9+: Excelente.

Cross-Entropy Loss

$$H(p, q) = - \sum p_i \log(q_i)$$

Mide la diferencia entre probabilidades predichas y reales. Es una métrica de optimización.

Clasificación multiclase

La **clasificación multiclase** aparece cuando el modelo debe asignar cada instancia a una de k clases, con $k > 3$. A diferencia de la clasificación binaria, donde solo hay dos etiquetas posibles, aquí el objetivo es escoger **una única clase** entre varias (por ejemplo: **negative**, **COVID-19**, **pneumonia** y **tuberculosis**).

Matriz de confusión $k \times k$

Los resultados del clasificador se representan mediante una **matriz de confusión** de tamaño $k \times k$. Cada elemento n_{ij} indica cuántas instancias cuya clase real es i fueron clasificadas como j .

- Los elementos de la diagonal n_{ii} representan aciertos.
- Los elementos fuera de la diagonal representan errores (confusiones entre clases).

Reducir multiclase a binario (one-vs-all)

Para calcular métricas como **precision**, **recall** o **F1** (definidas originalmente para binario), se suele transformar el problema en k problemas binarios **one-vs-all**.

Para cada clase i :

- $TP_i = n_{ii}$
- $FN_i = \sum_{j \neq i} n_{ij}$ (instancias reales de i mal clasificadas)
- $FP_i = \sum_{j \neq i} n_{ji}$ (instancias de otras clases clasificadas como i)
- $TN_i = \sum_{j \neq i} \sum_{h \neq i} n_{jh}$ (todo lo demás)

Con estos valores, se pueden calcular para cada clase i las métricas de binario: **precision**, **recall**, **specificity**, **F1**, etc.

Macro-averaging

En **macro-averaging** se calcula la métrica por separado para cada clase y luego se promedia:

$$\text{Macro-Métrica} = \frac{1}{k} \sum_{i=1}^k \text{Métrica}_i$$

Esto asigna **el mismo peso a cada clase**, independientemente de cuántas instancias tenga. Es especialmente útil cuando hay **desbalance** entre clases, porque evita que las clases grandes dominen el resultado.

Micro-averaging

En **micro-averaging** primero se suman globalmente los conteos de todas las clases y luego se calcula la métrica una sola vez:

$$TP = \sum_{i=1}^k TP_i, \quad FP = \sum_{i=1}^k FP_i, \quad FN = \sum_{i=1}^k FN_i, \quad TN = \sum_{i=1}^k TN_i$$

Luego se aplica la fórmula de la métrica (por ejemplo precision o recall) usando esos totales.

Este enfoque da **el mismo peso a cada instancia**, por lo que puede verse dominado por las clases más numerosas.

Accuracy en multiclase

La **accuracy** en multiclase se calcula como el número total de aciertos (diagonal) dividido entre el total de instancias:

$$\text{Acc} = \frac{\sum_{i=1}^k n_{ii}}{n}$$

Cohen's Kappa (κ) en multiclase

Cohen's κ mide cuánto mejor es el clasificador que el azar.

$$\kappa = \frac{p_0 - p_e}{1 - p_e}$$

donde:

$$p_0 = \frac{1}{n} \sum_{i=1}^k n_{ii}$$

es la precisión observada, y

$$p_e = \frac{1}{n^2} \sum_{i=1}^k n_{i \cdot} \cdot n_{\cdot i}$$

es la precisión esperada por azar (usando los totales por fila y por columna).

MCC en multiclase

El **Matthews Correlation Coefficient** también tiene versión multiclase:

$$\text{MCC} = \frac{n \sum_{i=1}^k n_{ii} - \sum_{i=1}^k n_{i \cdot} \cdot n_{\cdot i}}{\sqrt{\left(n^2 - \sum_{i=1}^k n_{i \cdot}^2\right) \left(n^2 - \sum_{i=1}^k n_{\cdot i}^2\right)}}$$

Al igual que en binario, el MCC toma valores en $[-1, 1]$:

- 1: clasificación perfecta
- 0: comportamiento aleatorio
- -1: clasificación completamente opuesta

En el caso especial $k = 2$, tanto κ como MCC se reducen a sus fórmulas de clasificación binaria.